

SENTINELA · D8 — Statistical Computing with R & Python

Global Solution 2026.1 · FIAP · Indústria Espacial

Dupla: Rafael & Charles

Objetivo: Coleta, organização e análise estatística de dados climáticos do Rio Grande do Sul

Dataset: INMET — Estações automáticas do RS (2014–2025, 12 anos)

Cidades: Porto Alegre, Santa Maria, Passo Fundo, Bento Gonçalves, Teutônia

Conexão SENTINELA: Este dataset é o mesmo utilizado nos modelos de ML (D5) e Rede Neural (D7)

1. Importação de bibliotecas

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import seaborn as sns
from scipy import stats
import warnings
warnings.filterwarnings('ignore')

# Configurações globais de estilo
plt.rcParams['figure.dpi'] = 120
plt.rcParams['font.family'] = 'DejaVu Sans'
sns.set_theme(style='whitegrid', palette='muted')

print('Bibliotecas carregadas com sucesso!')
```

Bibliotecas carregadas com sucesso!

2. Carregamento e limpeza dos dados do INMET

2.1 Upload dos arquivos anuais

Baixe de portal.inmet.gov.br/dadoshistoricos um arquivo ZIP por ano, de **2014 a 2025**. Faça upload de todos de uma vez na célula abaixo (use Ctrl+clique para selecionar múltiplos). O código localiza automaticamente as 5 estações do RS pelo código WMO em cada ano.

```
from google.colab import files
import os

# — UPLOAD DOS ZIPs ANUAIS DO INMET (2014 a 2025) —————
# Baixe de https://portal.inmet.gov.br/dadoshistoricos um ZIP por ano.
# Faça upload de todos de uma vez (Ctrl+clique para selecionar vários).
print("Selecione os arquivos ZIP anuais do INMET (2014.zip ate 2025.zip)...")
uploaded = files.upload()

for fn in uploaded.keys():
    print(f'Arquivo "{fn}" ({len(uploaded[fn])/1024/1024:.1f} MB) carregado')

print("\nArquivos no ambiente:", [a for a in os.listdir('.') if a.endswith('.zip')])
```

Selecione os arquivos ZIP anuais do INMET (2014.zip ate 2025.zip)...

Escolher arquivos Nenhum arquivo escolhido Upload widget is only available when the cell has been executed in the current browser session. Please rerun this cell to enable.

Saving 2014.zip to 2014.zip
 Saving 2015.zip to 2015.zip
 Saving 2016.zip to 2016.zip
 Saving 2017.zip to 2017.zip
 Saving 2018.zip to 2018.zip
 Saving 2019.zip to 2019.zip
 Saving 2020.zip to 2020.zip
 Saving 2021.zip to 2021.zip
 Saving 2022.zip to 2022.zip
 Saving 2023.zip to 2023.zip
 Saving 2024.zip to 2024.zip
 Saving 2025.zip to 2025.zip
 Arquivo "2014.zip" (94.3 MB) carregado
 Arquivo "2015.zip" (93.4 MB) carregado
 Arquivo "2016.zip" (97.7 MB) carregado
 Arquivo "2017.zip" (104.6 MB) carregado
 Arquivo "2018.zip" (112.4 MB) carregado
 Arquivo "2019.zip" (112.1 MB) carregado
 Arquivo "2020.zip" (98.9 MB) carregado
 Arquivo "2021.zip" (76.8 MB) carregado
 Arquivo "2022.zip" (86.2 MB) carregado
 Arquivo "2023.zip" (102.1 MB) carregado
 Arquivo "2024.zip" (98.0 MB) carregado
 Arquivo "2025.zip" (86.7 MB) carregado

Arquivos no ambiente: ['2017.zip', '2025.zip', '2022.zip', '2019.zip', '2016.zip', '2021.zip', '2014.zip', '2020.zip', '2024.zip']

Agora que os arquivos foram carregados para o ambiente do Colab, você pode executar a célula abaixo (que você já possui) para processar o dataframe (`df`).

```
import zipfile
import os
import glob
import pandas as pd
import numpy as np

# — DESCOMPACTAR TODOS OS ZIPs ANUAIS —————
anos = range(2014, 2026) # 2014 ate 2025 (12 anos)
for ano in anos:
    zip_nome = f'{ano}.zip'
    if os.path.exists(zip_nome):
        with zipfile.ZipFile(zip_nome, 'r') as zip_ref:
            zip_ref.extractall(f'{ano}')
            print(f'✓ {zip_nome} descompactado')

# — CIDADES-ALVO (código WMO da estação) —————
# Usamos o código WMO porque o nome do arquivo varia de ano para ano.
cidades_wmo = {
    'Porto Alegre' : 'A801',
    'Santa Maria' : 'A803',
    'Passo Fundo' : 'A839',
    'Bento Gonçalves': 'A840',
    'Teutônia' : 'A882',
}

COLUNAS = [
    'data', 'hora_utc', 'precipitacao_mm', 'pressao_hpa',
    'pressao_max_hpa', 'pressao_min_hpa', 'radiacao_kj',
    'temperatura_c', 'temp_orvalho_c', 'temp_max_c', 'temp_min_c',
    'orvalho_max_c', 'orvalho_min_c', 'umidade_max_pct',
    'umidade_min_pct', 'umidade_pct', 'vento_dir_gr',
    'vento_rajada_ms', 'vento_vel_ms'
]

def localizar_arquivos(wmo):
    """Procura todos os CSVs de uma estação (por código WMO) em todas as pastas de ano."""
    padrao = f'**/INMET_S_RS_{wmo}_*.CSV'
    encontrados = glob.glob(padrao, recursive=True)
    # Alguns anos vêm com extensão minúscula
    encontrados += glob.glob(f'**/INMET_S_RS_{wmo}_*.csv', recursive=True)
    return sorted(set(encontrados))

def carregar_csv(caminho, cidade):
    """Carrega e limpa UM CSV anual do INMET, retornando DataFrame diário."""
    try:
        df = pd.read_csv(caminho, sep=';', encoding='latin-1',
                        skiprows=8, decimal=',',
                        na_values=['-9999', '-9999.0', '', ' '])
        df = df.iloc[:, :len(COLUNAS)]
    except:
```

```

df.columns = COLUNAS

df['data'] = pd.to_datetime(df['data'], format='%Y/%m/%d', errors='coerce')
# Alguns anos usam formato YYYY-MM-DD
mask_na = df['data'].isna()
if mask_na.any():
    df.loc[mask_na, 'data'] = pd.to_datetime(
        df.loc[mask_na, 'data'], errors='coerce')
df = df.dropna(subset=['data'])

for col in ['precipitacao_mm', 'temperatura_c', 'temp_max_c', 'temp_min_c',
            'umidade_pct', 'pressao_hpa', 'vento_rajada_ms']:
    df[col] = pd.to_numeric(df[col], errors='coerce')

# Filtros físicos de sanidade
df.loc[df['temperatura_c'].abs() > 60, 'temperatura_c'] = np.nan
df.loc[(df['umidade_pct'] > 100) | (df['umidade_pct'] < 0), 'umidade_pct'] = np.nan
df.loc[df['precipitacao_mm'] < 0, 'precipitacao_mm'] = np.nan

diario = df.groupby('data').agg(
    precipitacao_mm=('precipitacao_mm', 'sum'),
    temperatura_media_c=('temperatura_c', 'mean'),
    temperatura_max_c=('temp_max_c', 'max'),
    temperatura_min_c=('temp_min_c', 'min'),
    umidade_media_pct=('umidade_pct', 'mean'),
    pressao_media_hpa=('pressao_hpa', 'mean'),
    vento_max_ms=('vento_rajada_ms', 'max'),
).reset_index()
diario['cidade'] = cidade
return diario
except Exception as e:
    print(f'    Δ erro em {os.path.basename(caminho)}: {e}')
    return pd.DataFrame()

# — CARREGA TODOS OS ANOS DE TODAS AS CIDADES —————
dfs = []
print('\nCarregando series historicas 2014-2025...\n')
for cidade, wmo in cidades_wmo.items():
    arquivos_cidade = localizar_arquivos(wmo)
    if not arquivos_cidade:
        print(f'X {cidade:18s} ({wmo}): nenhum arquivo encontrado')
        continue
    partes = [carregar_csv(arq, cidade) for arq in arquivos_cidade]
    partes = [p for p in partes if not p.empty]
    if partes:
        df_cidade = pd.concat(partes, ignore_index=True).drop_duplicates('data')
        dfs.append(df_cidade)
        anos_cob = f"{df_cidade['data'].dt.year.min()}-{df_cidade['data'].dt.year.max()}"
        print(f'✓ {cidade:18s} ({wmo}): {len(df_cidade):5d} dias | {len(arquivos_cidade):2d} anos | {anos_cob}')

# — CONSOLIDA —————
df = pd.concat(dfs, ignore_index=True)
df['mes'] = df['data'].dt.month
df['ano'] = df['data'].dt.year
df['evento_extremo'] = (df['precipitacao_mm'] >= 30).astype(int)

print(f'\n{"="*60}')
print(f'Total geral: {len(df):,} registros diarios')
print(f'Periodo: {df["data"].min().date()} a {df["data"].max().date()}')
print(f'Cidades: {df["cidade"].nunique()} | Anos: {df["ano"].nunique()}')
print(f'Eventos extremos (>=30mm): {df["evento_extremo"].sum():,} dias ({df["evento_extremo"].mean()*100:.1f}%)')
print(f'{"="*60}')
df.head()

```

```

✓ 2014.zip descompactado
✓ 2015.zip descompactado
✓ 2016.zip descompactado
✓ 2017.zip descompactado
✓ 2018.zip descompactado
✓ 2019.zip descompactado
✓ 2020.zip descompactado
✓ 2021.zip descompactado
✓ 2022.zip descompactado
✓ 2023.zip descompactado
✓ 2024.zip descompactado
✓ 2025.zip descompactado

```

Carregando series historicas 2014-2025...

```

✓ Porto Alegre      (A801): 2557 dias | 12 anos | 2019-2025
✓ Santa Maria      (A803): 2557 dias | 12 anos | 2019-2025
✓ Passo Fundo      (A839): 2557 dias | 12 anos | 2019-2025
✓ Bento Gonçalves  (A840): 2557 dias | 12 anos | 2019-2025
✓ Teutônia         (A882): 2557 dias | 12 anos | 2019-2025

```

```

=====
Total geral: 12,785 registros diarios
Periodo: 2019-01-01 a 2025-12-31
Cidades: 5 | Anos: 7
Eventos extremos (>=30mm): 510 dias (4.0%)
=====

```

	data	precipitacao_mm	temperatura_media_c	temperatura_max_c	temperatura_min_c	umidade_media_pct	pressao_media_hpa
0	2019-01-01	0.0	28.733333	36.4	23.3	72.916667	1006.220833
1	2019-01-02	0.0	30.533333	38.5	24.3	66.666667	1003.462500
2	2019-01-03	11.0	26.925000	34.1	21.1	83.625000	1001.237500
3	2019-01-04	3.0	21.950000	26.0	19.6	88.541667	1007.608333

3. Tabela de Distribuição de Frequências — Precipitação Diária

```

# — FAIXAS DE PRECIPITAÇÃO —————
# Thresholds baseados em critérios meteorológicos do INMET e OMM:
# 0-5mm → sem chuva significativa
# 5-15mm → chuva fraca a moderada
# 15-30mm → chuva moderada a forte
# 30-60mm → evento intenso (threshold de alerta)
# >60mm → evento extremo (risco de enchente)

bins = [0, 5, 15, 30, 60, float('inf')]
labels = ['0-5 mm (sem signif.)', '5-15 mm (fraca/mod.)',
          '15-30 mm (mod./forte)', '30-60 mm (intensa)', '>60 mm (extrema)']

precip_todos = df['precipitacao_mm'].dropna()
precip_todos = precip_todos[precip_todos > 0] # apenas dias com chuva

freq_abs = pd.cut(precip_todos, bins=bins, labels=labels, right=False).value_counts().sort_index()
freq_rel = (freq_abs / freq_abs.sum() * 100).round(2)
freq_acum = freq_rel.cumsum().round(2)

tabela_freq = pd.DataFrame({
    'Faixa de Precipitação' : labels,
    'Freq. Absoluta (dias)' : freq_abs.values,
    'Freq. Relativa (%)' : freq_rel.values,
    'Freq. Acumulada (%)' : freq_acum.values,
})

print('=' * 70)
print('TABELA DE DISTRIBUIÇÃO DE FREQUÊNCIAS – PRECIPITAÇÃO DIÁRIA')
print('Dados: 5 estações do RS • 2014-2025 • Apenas dias com precipitação > 0mm')
print('=' * 70)
print(tabela_freq.to_string(index=False))
print('=' * 70)
print(f'Total de dias com chuva: {freq_abs.sum()}')
print(f'Dias com evento extremo (≥30mm): {freq_abs.iloc[3:].sum()} '
      f'f'({freq_rel.iloc[3:].sum():.1f})% dos dias chuvosos')

```

```

=====
TABELA DE DISTRIBUIÇÃO DE FREQUÊNCIAS – PRECIPITAÇÃO DIÁRIA
Dados: 5 estações do RS • 2014-2025 • Apenas dias com precipitação > 0mm
=====
Faixa de Precipitação  Freq. Absoluta (dias)  Freq. Relativa (%)  Freq. Acumulada (%)

```

0-5 mm (sem signif.)	2764	55.09	55.09
5-15 mm (fraca/mod.)	1096	21.85	76.94
15-30 mm (mod./forte)	647	12.90	89.84
30-60 mm (intensa)	385	7.67	97.51
>60 mm (extrema)	125	2.49	100.00

=====

Total de dias com chuva: 5017

Dias com evento extremo (≥ 30 mm): 510 (10.2% dos dias chuvosos)

Interpretação: A tabela revela que a grande maioria dos dias com precipitação no RS concentra-se nas faixas de baixa intensidade (0-15mm). Porém, os eventos acima de 30mm — considerados intensos pelo INMET — representam uma parcela que, embora minoritária em dias, é responsável pelo maior volume acumulado e pelos maiores riscos de enchente. Esta distribuição assimétrica justifica a escolha de modelos de classificação como os utilizados no D5 e D7 do SENTINELA.

4. Medidas Descritivas por Cidade

```
from scipy.stats import mode as scipy_mode

def moda_segura(x):
    x = x.dropna()
    if len(x) == 0: return np.nan
    resultado = scipy_mode(x.round(1), keepdims=True)
    return round(float(resultado.mode[0]), 2)

descritivas = df.groupby('cidade')['precipitacao_mm'].agg(
    N='count',
    Media=lambda x: round(x.mean(), 2),
    Mediana=lambda x: round(x.median(), 2),
    Moda=moda_segura,
    Desvio_Pad=lambda x: round(x.std(), 2),
    Variancia=lambda x: round(x.var(), 2),
    Minimo=lambda x: round(x.min(), 2),
    Q1=lambda x: round(x.quantile(0.25), 2),
    Q3=lambda x: round(x.quantile(0.75), 2),
    Maximo=lambda x: round(x.max(), 2),
    IQR=lambda x: round(x.quantile(0.75) - x.quantile(0.25), 2),
    Eventos_Extremos=lambda x: int((x >= 30).sum()),
).reset_index()

print('=' * 80)
print('MEDIDAS DESCRITIVAS - PRECIPITAÇÃO DIÁRIA (mm) POR CIDADE - RS 2014-2025')
print('=' * 80)
print(descritivas.to_string(index=False))
print('=' * 80)

# Medidas descritivas por mês (Porto Alegre)
print('\nMEDIDAS DESCRITIVAS MENSAIS - PORTO ALEGRE (2014-2025)')
meses_poa = df[df['cidade']=='Porto Alegre'].groupby('mes')['precipitacao_mm'].agg(
    Media=lambda x: round(x.mean(), 2),
    Desvio=lambda x: round(x.std(), 2),
    Max=lambda x: round(x.max(), 2),
    Eventos_30mm=lambda x: int((x >= 30).sum())
).reset_index()
print(meses_poa.to_string(index=False))
```

```
=====
MEDIDAS DESCRITIVAS - PRECIPITAÇÃO DIÁRIA (mm) POR CIDADE - RS 2014-2025
=====
```

	cidade	N	Media	Mediana	Moda	Desvio_Pad	Variancia	Minimo	Q1	Q3	Maximo	IQR	Eventos_Extremos
	Bento Gonçalves	2557	3.92	0.0	0.0	11.73	137.70	0.0	0.0	1.4	159.6	1.4	85
	Passo Fundo	2557	4.69	0.0	0.0	12.70	161.24	0.0	0.0	2.2	155.0	2.2	117
	Porto Alegre	2557	4.34	0.0	0.0	11.59	134.24	0.0	0.0	1.8	126.2	1.8	101
	Santa Maria	2557	4.52	0.0	0.0	13.55	183.61	0.0	0.0	1.0	207.0	1.0	120
	Teutônia	2557	3.56	0.0	0.0	11.09	122.93	0.0	0.0	0.2	118.0	0.2	87

```
=====
```

```
MEDIDAS DESCRITIVAS MENSAIS - PORTO ALEGRE (2014-2025)
```

mes	Media	Desvio	Max	Eventos_30mm
1	4.13	9.63	68.8	6
2	2.92	7.46	41.4	4
3	2.77	8.42	56.4	5
4	3.66	12.24	109.0	9
5	7.05	16.00	126.2	15
6	6.02	17.13	122.6	13
7	4.46	12.19	87.6	9
8	3.36	10.24	92.4	6
9	6.74	12.97	66.2	15
10	3.74	8.84	54.4	7
11	3.50	9.37	66.2	5
12	3.64	9.32	60.0	7

Interpretação: A comparação entre as cidades evidencia diferenças significativas de variabilidade. O alto desvio padrão indica distribuição assimétrica positiva característica de séries climáticas — a mediana é sistematicamente menor que a média, confirmando a presença de eventos extremos que puxam a média para cima. O IQR (diferença entre Q3 e Q1) revela que 50% dos dias chuvosos concentram precipitação num intervalo relativamente estreito, enquanto os eventos extremos ficam na cauda superior da distribuição.

5. Gráfico 1 — Histograma da Distribuição de Precipitação

```
if not df.empty and df['precipitacao_mm'].max() > 0:
    fig, ax = plt.subplots(figsize=(10, 5))

    precip_plot = df['precipitacao_mm'][df['precipitacao_mm'] > 0].dropna()


    ax.hist(precip_plot, bins=40, color='#2E86AB', edgecolor='white',
            linewidth=0.5, alpha=0.85, label='Dias com chuva')

    # Linha de threshold de evento extremo
    ax.axvline(x=30, color='#E63946', linewidth=2, linestyle='--',
              label='Threshold evento extremo (30mm)')
    ax.axvline(x=precip_plot.mean(), color='#F4A261', linewidth=2,
              linestyle=':', label=f'Média ({precip_plot.mean():.1f}mm)')
    ax.axvline(x=precip_plot.median(), color='#2A9D8F', linewidth=2,
              linestyle='-.', label=f'Mediana ({precip_plot.median():.1f}mm)')

    ax.set_title('Distribuição de Precipitação Diária\n5 Estações do RS · INMET 2014-2025',
                fontsize=13, fontweight='bold', pad=12)
    ax.set_xlabel('Precipitação diária (mm)', fontsize=11)
    ax.set_ylabel('Número de dias', fontsize=11)
    ax.legend(fontsize=9)

    # Define o limite do eixo apenas se houver dados para evitar NaN
    upper_limit = precip_plot.quantile(0.99)
    if pd.notnull(upper_limit):
        ax.set_xlim(0, upper_limit)

    plt.tight_layout()
    plt.savefig('sentinela_d8_histograma.png', dpi=150, bbox_inches='tight')
    plt.show()
    print('Gráfico salvo: sentinela_d8_histograma.png')
else:
    print("AVISO: Não há dados de precipitação suficientes para gerar o histograma. Verifique o carregamento dos arquivos.")
```



Interpretação: O histograma confirma a forte assimetria positiva (cauda longa à direita) típica de séries de precipitação. A grande concentração de dias em valores próximos de zero reflete o comportamento climático do RS, onde dias sem chuva são frequentes. A

linha vermelha tracejada em 30mm marca o threshold de evento extremo definido pelo INMET: dias além dessa linha representam risco de enchente e são a variável-alvo do modelo de classificação no D5.

6. Gráfico 2 — Boxplot Comparativo entre Cidades

```
fig, ax = plt.subplots(figsize=(11, 6))

# Ordena cidades pela mediana de precipitação
ordem = df.groupby('cidade')['precipitacao_mm'].median().sort_values(ascending=False).index

sns.boxplot(
    data=df[df['precipitacao_mm'] > 0],
    x='cidade', y='precipitacao_mm',
    order=ordem,
    palette='Blues_d',
    width=0.5,
    flierprops=dict(marker='o', markerfacecolor='#E63946',
                    markedgcolor='white', markersize=4, alpha=0.6),
    ax=ax
)

ax.axhline(y=30, color='#E63946', linewidth=1.8, linestyle='--',
          label='Threshold evento extremo (30mm)')

ax.set_title('Distribuição de Precipitação por Cidade\n(apenas dias com precipitação > 0mm) · RS 2014–2025\n'
            '(apenas dias com precipitação > 0mm) · RS 2014–2025',
            fontsize=13, fontweight='bold', pad=12)
ax.set_xlabel('Cidade', fontsize=11)
ax.set_ylabel('Precipitação diária (mm)', fontsize=11)
ax.legend(fontsize=9)
ax.set_ylim(0, df['precipitacao_mm'].quantile(0.97))
plt.tight_layout()
plt.savefig('sentinela_d8_boxplot.png', dpi=150, bbox_inches='tight')
plt.show()
print('Gráfico salvo: sentinela_d8_boxplot.png')
```

Interpretação: O boxplot comparativo entre as 5 cidades do RS revela padrões distintos de precipitação. Os pontos vermelhos (outliers) representam os eventos extremos — dias com precipitação muito acima do padrão habitual de cada cidade. A extensão dos bigodes e a posição das caixas mostram a variabilidade: cidades com caixas mais altas e bigodes mais longos indicam maior irregularidade climática e maior risco de eventos extremos, variável central para o sistema de alertas SENTINELA.

7. Gráfico 3 — Dispersão: Temperatura × Umidade

```
fig, ax = plt.subplots(figsize=(10, 6))

cidades_lista = df['cidade'].unique()
cores = sns.color_palette('tab10', len(cidades_lista))

for i, cidade in enumerate(cidades_lista):
    sub = df[df['cidade'] == cidade].dropna(subset=['temperatura_media_c', 'umidade_media_pct'])
    ax.scatter(
        sub['temperatura_media_c'],
        sub['umidade_media_pct'],
        c=[cores[i]], label=cidade,
        alpha=0.4, s=18, edgecolors='none'
    )

# Linha de tendência geral
dados_disp = df.dropna(subset=['temperatura_media_c', 'umidade_media_pct'])
z = np.polyfit(dados_disp['temperatura_media_c'], dados_disp['umidade_media_pct'], 1)
p = np.poly1d(z)
x_line = np.linspace(dados_disp['temperatura_media_c'].min(),
                    dados_disp['temperatura_media_c'].max(), 200)
ax.plot(x_line, p(x_line), color='#333333', linewidth=1.5,
      linestyle='--', label='Tendência geral')


# Correlação de Pearson
r, pval = stats.pearsonr(dados_disp['temperatura_media_c'], dados_disp['umidade_media_pct'])
ax.text(0.03, 0.93, f'r de Pearson = {r:.3f} (p = {pval:.2e})',
      transform=ax.transAxes, fontsize=9,
      bbox=dict(boxstyle='round', facecolor='ffffff', alpha=0.8))

ax.set_title('Temperatura Média × Umidade Relativa do Ar\n5 Cidades do RS · INMET 2014–2025',
            fontsize=13, fontweight='bold', pad=12)
ax.set_xlabel('Temperatura média diária (°C)', fontsize=11)
```

```

ax.set_ylabel('Umidade relativa média (%)', fontsize=11)
ax.legend(fontsize=9, loc='upper right')
plt.tight_layout()
plt.savefig('sentinela_d8_dispersao.png', dpi=150, bbox_inches='tight')
plt.show()
print(f'Correlação de Pearson: r = {r:.3f} | p-value = {pval:.2e}')

```



Interpretação: O gráfico de dispersão revela a relação inversa entre temperatura e umidade relativa — à medida que a temperatura aumenta, a capacidade do ar de reter vapor d'água cresce, reduzindo a umidade relativa medida. O coeficiente de Pearson (r negativo) confirma essa correlação inversamente proporcional, com significância estatística ($p < 0,05$). Este padrão é fisicamente consistente com a Lei de Clausius-Clapeyron e é uma das features mais relevantes para o modelo de classificação de risco climático no D5 do SENTINELA.

8. Gráfico 4 — Série Temporal de Precipitação Mensal Acumulada

```

# Precipitação mensal acumulada por cidade
mensal = df.groupby(['cidade', 'mes'])['precipitacao_mm'].sum().reset_index()
nomes_mes = {1: 'Jan', 2: 'Fev', 3: 'Mar', 4: 'Abr', 5: 'Mai', 6: 'Jun',
              7: 'Jul', 8: 'Ago', 9: 'Set', 10: 'Out', 11: 'Nov', 12: 'Dez'}
mensal['mes_nome'] = mensal['mes'].map(nomes_mes)

fig, ax = plt.subplots(figsize=(12, 6))
cores_linha = sns.color_palette('tab10', 5)

for i, cidade in enumerate(df['cidade'].unique()):
    sub = mensal[mensal['cidade'] == cidade].sort_values('mes')
    ax.plot(sub['mes'], sub['precipitacao_mm'],
            marker='o', markersize=6, linewidth=2,
            label=cidade, color=cores_linha[i])

ax.set_xticks(range(1, 13))
ax.set_xticklabels(list(nomes_mes.values()), fontsize=10)
ax.set_title('Precipitação Mensal Acumulada por Cidade\n5 Estações do RS · INMET 2014-2025',
             fontsize=13, fontweight='bold', pad=12)
ax.set_xlabel('Mês', fontsize=11)
ax.set_ylabel('Precipitação acumulada no mês (mm)', fontsize=11)
ax.legend(fontsize=9, loc='upper right')
ax.grid(axis='y', alpha=0.4)
plt.tight_layout()

```



```
plt.savefig('sentinela_d8_serie_temporal.png', dpi=150, bbox_inches='tight')
plt.show()
print('Gráfico salvo: sentinela d8 serie temporal.png')
```




Gráfico salvo: sentinela_d8_serie_temporal.png

Interpretação: A série temporal de precipitação mensal revela a sazonalidade climática do RS ao longo do período 2014–2025. Os meses de outono e início do inverno (março a junho) tendem a apresentar volumes mais elevados, padrão associado à entrada de frentes frias e ao regime de chuvas do sul do Brasil. As diferenças entre cidades refletem variações de altitude e posição geográfica — Bento Gonçalves e Caxias do Sul, em zona serrana, historicamente apresentam volumes diferentes de Porto Alegre na planície. Esses padrões sazonais são utilizados como features temporais nos modelos de predição do D5 e D7.

9. Resumo Executivo — Inteligência Acionável para o SENTINELA

Insight	Dado concreto	Aplicação no SENTINELA
Assimetria da precipitação	Mediana << Média em todas as cidades	Justifica uso de modelos robustos a outliers (XGBoost, D5)
Concentração de eventos extremos	X% dos dias com ≥30mm	Define threshold de alerta ALTO no app Python (D4)
Correlação temp × umidade	r de Pearson negativo e significativo	Feature de entrada para modelo de risco (D5/D7)
Sazonalidade	Picos em outono/inverno	Variável de mês como feature temporal no LSTM (D7)
Variabilidade entre cidades	Desvio padrão distinto por cidade	Justifica modelo por região no banco D3

Fonte dos dados: INMET — Instituto Nacional de Meteorologia · bdmet.inmet.gov.br

Licença: Dados públicos — uso livre para fins acadêmicos e de pesquisa

```
print('=' * 60)
```